

基于深度学习的绝缘子语义分割和自爆识别

摘要: 传统的人工电力检测工作存在诸多危险和弊端，随着深度学习的不断发展，其在电力巡检中的作用已初见端倪。本文借助于深度学习模型，完成了绝缘子掩膜分割和自爆绝缘子检测的任务。对于无人机拍摄的绝缘子图片进行适当预处理后，首先使用 Faster R-CNN 对图像中的绝缘子定位，再使用 Unet 对定位的图像进行语义分割，得到轮廓清晰的绝缘子掩膜图像。之后基于提取绝缘子的掩膜图，使用 Faster R-CNN + ResNet 101 识别掩膜图的自爆缺陷绝缘子。训练结果表明该方法可以很好的定位并分割出绝缘子掩膜，并对自爆绝缘子检测具有较高的精度。

关键词: 语义分割 特征识别 Faster R-CNN Unet

Abstract : There are many dangers and drawbacks in the traditional manual power inspection work. With the continuous development of deep learning, its role in power inspection has begun to take shape. In this paper, the deep learning model is used to complete the tasks of insulator mask segmentation and self-detonation insulator detection. After proper preprocessing of the insulator images taken by the drone, firstly we use Faster R-CNN to locate the insulator in the image, and then use Unet to semantically segment the positioned image to obtain a clear and noise-free insulator mask image. Afterwards, based on the mask map of the extracted insulator, Faster R-CNN + ResNet 101 was used to identify the self-explosive defect insulator of the mask map. The training results show that the method can locate and divide the insulator mask very well, and has high accuracy for the detection of self-detonating insulators.

Keywords : Semantic segmentation Feature recognition Faster R-CNN Unet

目 录

一、 简介	4
二、 分析方法与过程	4
2.1 绝缘子语义分割.....	5
2.1.1 流程图.....	5
2.1.2 数据预处理.....	5
2.1.3 Faster R-CNN 对绝缘子进行定位.....	7
2.1.4 Unet 提取绝缘子掩膜	10
2.2 自爆绝缘子位置检测.....	14
2.2.1 流程图.....	14
2.2.2 基于 Faster R-CNN+ResNet 101 进行绝缘子自爆检测.....	14
2.2.2 结果分析.....	15
三、 结论	16
四、 参考文献.....	17

一、简介

由于传统的电网巡检方式中通过人工操作存在一定的危险和误差，为了保障巡检人员的安全性和巡检结果的精度，需要一套更为合理高效的流程和方法取代传统的人力作业。深度学习凭借其自动化、智能化的优势逐渐为电力巡检人员所青睐。借助深度学习实现电力智能巡检已成为当下的研究热门课题之一。

通过官方提供的有限的绝缘子图片数据，对图像进行数据增强和预处理后，借助 Faster R-CNN、Unet 等算法来实现以下目标：

- (1) 通过旋转等方式对既有图片进行预处理以实现数据增强
- (2) 基于数据增强后的绝缘子图片利用 Faster R-CNN 进行语义识别绝缘子，定位绝缘子后借助 Unet 对图像中的绝缘子部分进行分割，并生成去除背景的绝缘子的掩膜图
- (3) 借助 Faster R-CNN 对分割后的图像进行图像识别，并检测分割绝缘子后，对识别出的自爆绝缘子位置利用 bonding box 进行标记

二、分析方法与过程




图 1 系统流程图

2.1 绝缘子语义分割

2.1.1 流程图

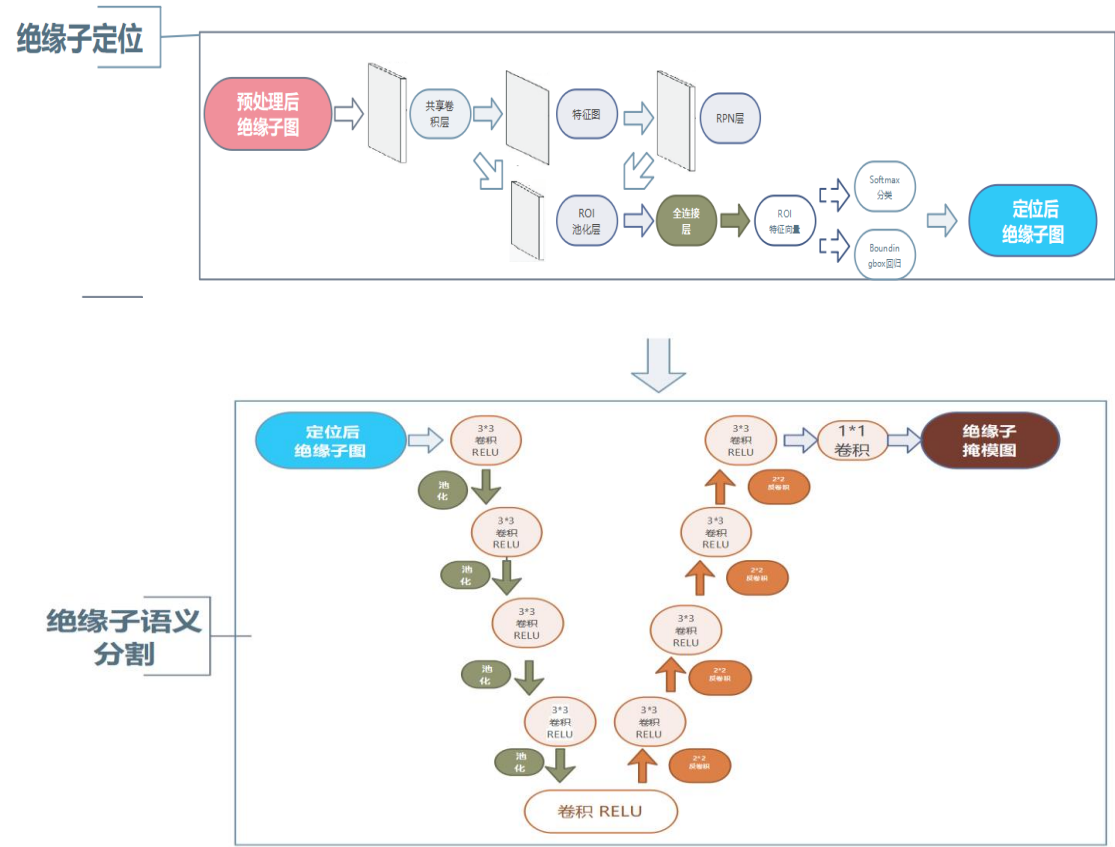


图2 绝缘子掩膜提取流程

2.1.2 数据预处理

由于（1）给出绝缘子图像数量有限

（2）原图给出图片均为 4K 过于庞大，且每张图片的大小不一

（3）绝缘子图片样本的背景不一，复杂多样

（4）每张图的绝缘子存在旋转方向不一

因而需要对绝缘子图片进行如下图处理后，制作成深度学习的训练集和验证

集后投入使用:

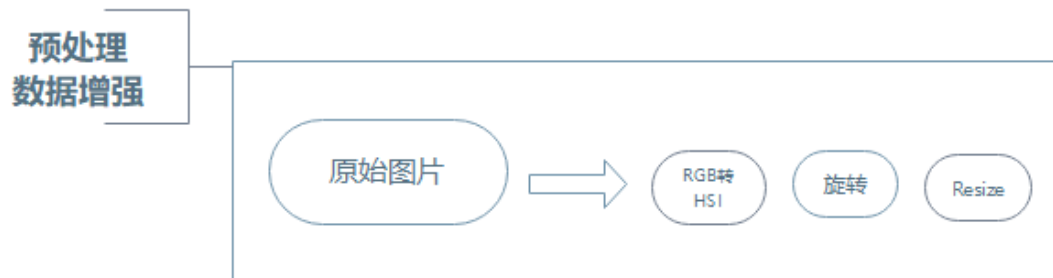


图 3 预处理步骤

(1) 对绝缘子图片进行旋转，每一张图片分别进行连续的 7 次 45° 旋转以得到不同方向的 8 张图片

(2) 通过将 RGB 颜色空间转换至 HSI 空间后, 对 H 和 S 通道进行阈值分割后再高斯模糊, 从而实现图像增强并减少图像噪声, 便于提取绝缘子

(3) 为使得模型具有良好的泛化性, 对每张图片进行了 `resize` 使得变形后的图片为 512*512 大小




图 4 预处理步骤对比

2.1.3 Faster R-CNN 对绝缘子进行定位

1. 原理

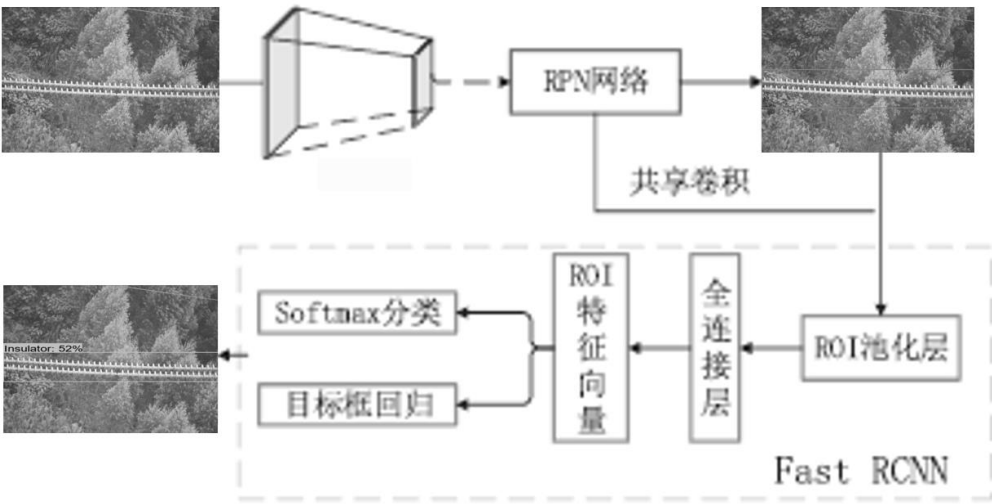


图5 Faster R-CNN 结构图

Faster R-CNN 在 Fast R-CNN 的基础上提出了 Region Proposal Network 网络，PRN 基于 ROI Pooling 的框架，对 SPPnet 进行简化，将在原图中进行穷举滑动转换成比缩小的特征空间后滑动窗口。相比于 R-CNN 和 Fast R-CNN，其将区域生成、分类，定位全部融入到一个网络当中，实现了 GPU 的运算，极大的加快了神经网络的训练与测试，在速度与性能上取得了极大的提升。

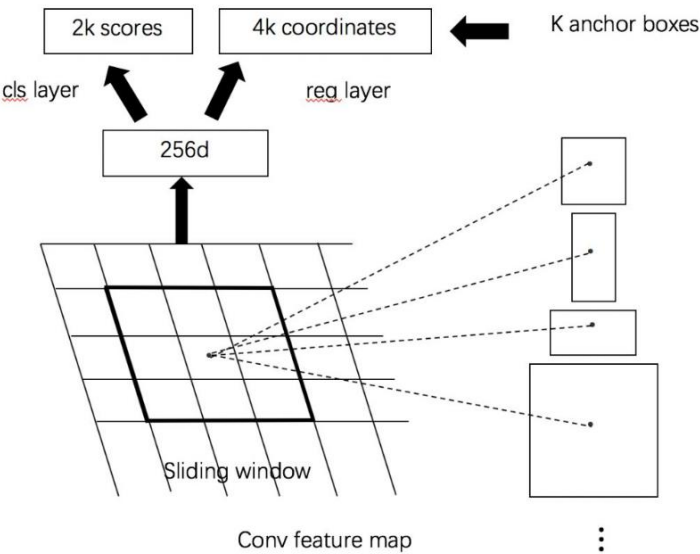


图 6 Region Proposal Network 网络

2. 训练过程

a. 预训练

通过拥有的庞大图片量的 COCO 数据集，对模型进行预训练。由于网络的复杂程度不同，为了在网络深度很大的情况下使得计算性能得到提升，且 Inception v2 相对于 v3、v4 泛化和计算能力更强。其通过对较大运算卷积核的分解和对称卷积的转换，提升了处理性能；同时扩宽了滤波器组，减少信息损失。这里选取 Inception v2 作为特征提取网络进行预训练。经由预训练后对数据增强后的绝缘子图像使用开源软件 LabelImg 进行标注得到数据集，分为训练集和测试集，进行训练。

b. 训练 PRN 和 Fast R-CNN 网络

经过预训练后，使用 3×3 的滑动窗口对卷积层的特征图进行卷积得到特征向量，同时提供以滑动窗口为中心 3 种尺度 3 种长宽比的 9 种区域建议，使得定位的精确性得到提升。RPN 层根据候选框和 Ground Truth 的最大重叠不断确定候选框是否是物体，再通过得到的区域建议从而对 Fast R-CNN 进行训练。

c. 目标检测

通过由 RPN 生成的目标候选框进行高得分框的筛选，将得到的区域和特征网络 Inception V2 对应特征层结合 Fast R-CNN 进行计算。全连接和 softmax 对区域进行分类后再次对区域进行回归，以获取更高精度的候选框。从而检查目标，得到绝缘子的检测结果。

d. 训练算法及参数

传统的深度学习训练算法多种多样，如 SGD、Momentum、AdaGrad、RMSProp 等。经过试验，这里选取自适应性强且收敛速度快的 Adam 作为模

型的训练算法。训练参数设置如下：步长设置为 0.00001，一次迭代的图像数量 batch_size 根据显卡性能选取为 8，迭代次数为 10 万次。

2. 实验结果

Faster R-CNN 的损失函数如下式，分为 RPN 的损失函数和 Fast R-CNN 的损失函数。其中两部分的损失函数包含有分类损失 cls loss 和回归损失 bbox regression loss。

$$L(p_i, t_i) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*)$$

其中， p_i 为 anchor 预测目标的概率， p_i^* 为 GroundTruth 标签， t_i 是表示预测 bounding box 的坐标向量， t_i^* 为 positive anchor 对应的 GroundTruth 的坐标向量， $L_{cls}(p_i, p_i^*)$ 为两类的对数损失， $L_{reg}(t_i, t_i^*)$ 为回归损失， N_{cls} 为 anchor 的数量， N_{reg} 是 mini-batch 的大小， λ 为权重系数 10。经过计算得到 loss 曲线如下图所示。

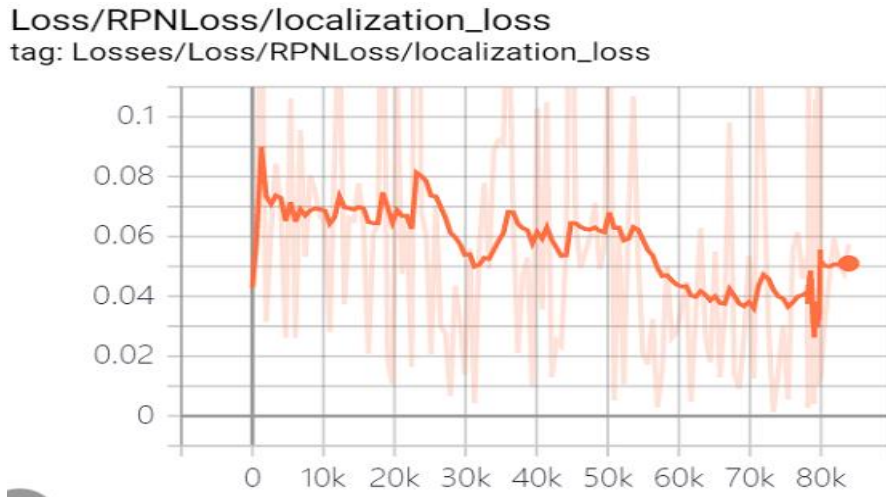


图 7 Loss 曲线

将 Loss 曲线可视化后可以得知，经过 7 万次迭代后 Total Loss 已经趋于平稳，最终收敛于 0.2 附近，Localization Loss 收敛于 0.06 附近，训练效果

良好。若时间充足的情况下给予进一步训练可能会达到更好的损失。取置信度为 0.5 时，定位精度达到 80%。定位效果如下图：



图 8 Faster R-CNN 定位绝缘子结果

2.1.4 Unet 提取绝缘子掩膜

1. 原理

作为语义分割常用的网络结构,Unet 网络在类似 FCN 网络执行下采样提取特征上采样特征融合的基础上,引入 U 型对称处理、编码——解码结构和 Overlap-tile 方法,并更改 Skip Connection 中的加和操作为叠加操作,上采样采用反卷积,同时对损失函数中的边界给予更大权重值,能够进一步使得低分辨率信息和高分辨率信息相结合,并获得精度更高更为准确的图像分割结果。其不仅在医学图像分割中获取广泛的应用,在各类图像分割的应用中也受到青睐。

2. 训练过程




图9 Unet 结构

a. 图像预处理

对于已通过 Faster R-CNN 获得绝缘子位置的图像提取出绝缘子串的图片，再对绝缘子串图像做如下图所示预处理：根据长宽比的不同将每一张图片分成多个小块。目的是进行数据增强，经过复杂的图像切割以得到更丰富的训练集样本，同时提高掩膜转换的效率。待模型识别出掩膜图后，再将图片拼接成原图大小。

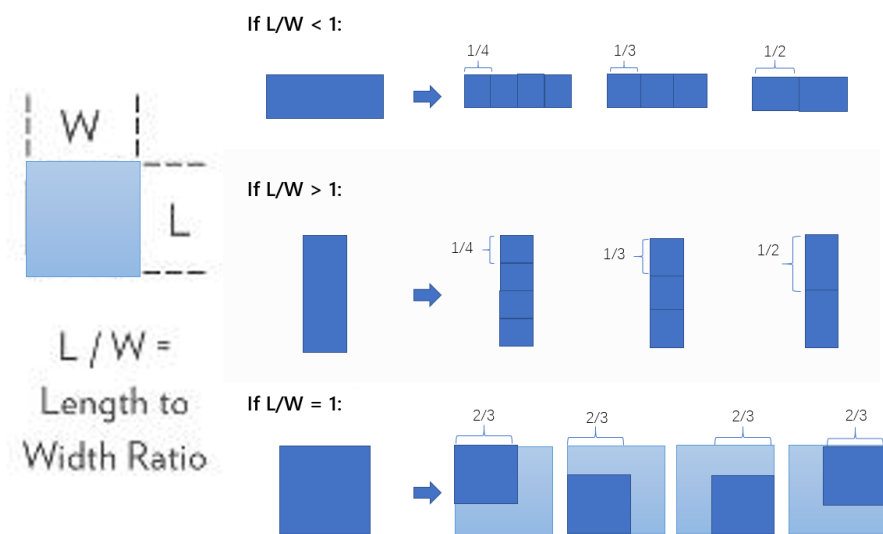


图10 依据长宽比不同的裁剪

b. 编码下采样

经由预处理获得充足的训练集后，为进一步提取绝缘子的掩膜图，经过试验选取 Unet 网络进行该项任务。首先将定位出绝缘子的图像编码，编码过程也是下采样过程，每通过一个池化层提取一个尺度，经过不同的卷积从而得到不同尺度的特征并是的特征通道的数量翻倍，进行特征提取过程。包含一个 2×2 卷积使得通道减半和两个 3×3 的卷积加 RELU 单元并与解码部分进行传递连接其中根据图像不同的长宽比执行如图示过程。

c. 解码上采样

经过编码过程学习了不同层次的特征后通过不断反卷积的上采样，通道加倍后叠加对应通道数的图像在对拼接后的特征图像执行两次卷积，包含两个 3×3 的反卷积和一个 RELU 单元和步长为 2 的最大池化层，从而实现对绝缘子的精确定位并构建掩膜分割网络。最后使用一个 1×1 的卷积将特征向量映射输出，得到绝缘子的掩模图。

d. 模型训练

使用已进行数据增强并经由 Faster R-CNN 检测的图片作为训练集对 Unet 网络进行训练。由于显卡性能限制，其中参数 `batch_size` 即一次迭代的图像数量选取为 8，`step of epoch` 即一轮训练的步数设置为 300，`epoch` 即所有图像经过一次训练的数量设置为 50 轮。同样采用 Adam 对模型进行训练。

3. 实验结果

Dice 系数作为一种集合相似度的度量函数，可以较好的计算两个样本的相似度。根据任务要求，我们采用 Dice 系数来计算掩膜的精度和准确性，公式如下：

$$s = \frac{2|X \cap Y|}{|X| + |Y|}$$

其中 $|X \cap Y|$ 是 X 和 Y 之间的交集，可以近似为掩模图和 GroundTruth 图之间的点乘运算再加和， $|X|$ 和 $|Y|$ 分别表示 X 和 Y 的元素个数。由图可得出数据集平均在 92% 左右




图 11 Dice 在样本中的分布图

绝缘子语义分割的效果如下图：




图 12 Unet 提取绝缘子掩膜结果

2.2 自爆绝缘子位置检测

2.2.1 流程图

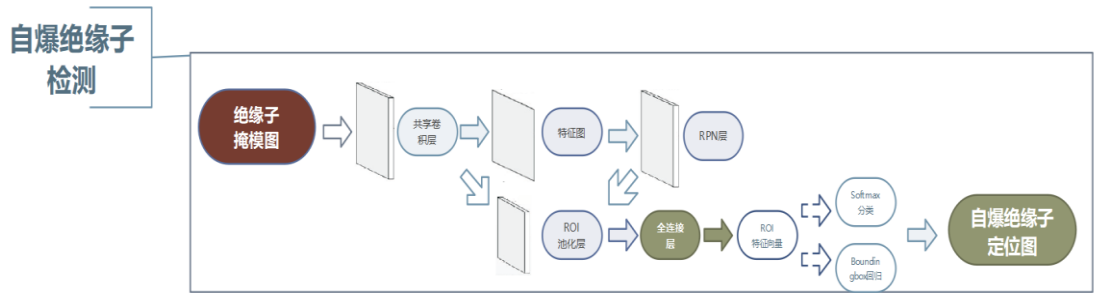


图 13 自爆绝缘子检测流程

2.2.2 基于 Faster R-CNN+ResNet 101 进行绝缘子自爆检测

鉴于 Faster R-CNN 网络具有较高的效率和精度，在检测自爆绝缘子的任务中我们仍然选用该网络。大致过程与绝缘子定位过程类似，借助于 KITTI 数据集中的大量训练图像，使得训练的模型拥有很强的泛化能力。此外，在自爆绝缘子检测的任务中，借助残差网络修正网络加深后的准确率，使用 ResNet 101 对 Faster R-CNN 的卷积层部分进行初始化。再将已得绝缘子掩膜图像中定位绝缘子后恢复原图尺寸，根据已标注的缺陷绝缘子图像送入模型进行训练。训练后对自爆绝缘子的准确率达到 90%左右。

2.2.2 结果分析




图 14 IOU

最大交并比 IOU（Intersection over Union）作为一种在数据集中检测识别准确度的方法，是检测算法性能的一个分厂中重要的函数。通过计算预测边框和真实边框的交交集和补集的比值从而评价模型的精度。经过计算得出 IOU 值平均在 89%左右，因而具有较好的拟合度。自爆绝缘子的识别效果如下图。



图 15 识别结果

三、结论

由于电力巡检中传统人工方法的诸多不利，已经无法适应当前的发展所需。因而亟需要一种更加合理高效的方法来完成该任务。在人工智能和图像处理技术日新月异的发展下，深度学习在智能电力巡检作业中的应用备受青睐，深度学习方法替代人工检测的电力巡检已经成为大势所趋。

基于绝缘子掩膜分割和自爆绝缘子检测的任务，本文首先对较少的原数据进行预处理和数据增强，再利用 Faster R-CNN 和 Unet 通过 Tensorflow 构建了绝缘子语义分割和自爆检测算法。通过实验和评测可以得知掩膜分割和自爆识别具有较高的准确率。希望本文可以为智能电力巡检技术提供理论依据，为深度学习在电力巡检中的应用助一臂之力。

四、参考文献

- [1] 吕易航. 航拍图像中绝缘子串检测、分割与自爆故障识别方法研究[D]. 郑州大学, 2019.
- [2] 晏琳, 景军锋, 李鹏飞. Faster RCNN 模型在坯布疵点检测中的应用[J]. 棉纺织技术, 2019(2):24-27.
- [3] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]. Medical Image Computing and Computer-Assisted Intervention, 2015: 234-241.
- [4] 庞春江, 张鹏程. 基于深度学习模型与稀疏表示的绝缘子状态分类[J]. 软件导刊, 2018, 017(005):40-42.
- [5] 李亚杰. 图像特征提取算法研究[J]. 科技广场, 2016(5):4-7.
- [6] 侯春萍, 章衡光, 张巍, 等. 输电线路绝缘子自爆缺陷识别方法[J]. 电力系统及其自动化学报, 2019, 31(6).
- [7] 丁圣勇, 樊勇兵, 陈楠. 基于 UNet 结构的人体骨骼点检测[J]. 广东通信技术, 2018, 038(011):64-69, 77.
- [8] 李承珊. 基于深度卷积神经网络的图像语义分割研究[D]. 2019.